

Amar Merabti

Data Scientist — Ingénieur Machine Learning & IA

merabtiamar91@gmail.com · merabtiamar.github.io · Paris, Île-de-France

Profil

Data Scientist à la recherche d'un CDI, disponible immédiatement. M2 IA & Data Science à l'Université Paris Cité, major de promotion (16/20). **Un an d'expérience** comme développeur machine learning chez ENAGEO (groupe Sonatrach), puis stage de fin d'études chez Nricher sur des données produit de production : chaîne de contrôle qualité automatique qui valide 68 % des valeurs extraites sans relecture humaine, à 99 % de précision. Python, PyTorch, NLP/LLM, pipelines distribués Kafka/Spark.

Compétences techniques

Programmation : Python, SQL, Java (Swing), C/C++

Outils : Git, Linux

Machine Learning : Scikit-Learn, régression linéaire et logistique, Ridge/Lasso, arbres de décision, Random Forest, Gradient Boosting (XGBoost, LightGBM), SVM, k-NN, Naive Bayes, MLP, K-means, DBSCAN, CAH, ACP, t-SNE, Isolation Forest, calibration

Deep Learning : PyTorch, TensorFlow, Keras, Transformers, LSTM, U-Net, entraînement multi-GPU, TabPFN, TabSTAR

NLP / LLM : BERT/DeBERTa, GPT-2, LLaMA, Mistral, DeepSeek, inférence textuelle (NLI), embeddings BGE-M3, fine-tuning, RAG

Data Engineering : Kafka, Spark/PySpark, Pandas, NumPy

Bases de données : MongoDB, MySQL, SQLite, SQL/NoSQL

Calcul GPU : Tesla T4, P100, NVIDIA L4, inférence par batch, fp16

Viz & BI : Streamlit, Power BI, SSIS

Expériences professionnelles

Data Scientist (stage de fin d'études) — Nricher, Paris

févr. – août 2026

- Conception d'un contrôle qualité automatique des attributs produit extraits (couleur, dimensions, matière, poids...), par inférence textuelle mDeBERTa-v3 couplée à un modèle tabulaire TabPFN, sur 4 catalogues clients et 35 attributs : **68 % des valeurs validées sans relecture humaine à 99 % de précision**, soit 42 % de volume de relecture en moins sur un circuit qui mobilisait 1 à 2 jours par catégorie de produits.
- Inférence GPU optimisée : batching, autocalc fp16, résolution dynamique des labels — **accélération de 20 à 50×** sur P100.
- Construction d'un jeu étiqueté de 30 919 lignes **sans aucune annotation manuelle**, à partir de 893 756 couples produit/attribution, via un pipeline de 8 transformations reproductibles (Python, Pandas).
- Évaluation comparative de 3 architectures sur 5 635 exécutions appariées : **0,925 d'exactitude équilibrée** pour la solution retenue (TabPFN sur scores NLI et embeddings réduits par ACP), contre 0,898 pour TabSTAR, écarté malgré sa lecture native du texte pour un **coût par exécution ×28**. Probabilités calibrées et seuil de décision réglable après coup, sans réentraînement : le point de fonctionnement reste au métier.
- Écriture et exécution d'algorithmes d'extraction d'attributs par règles et lexiques, normalisation vers le référentiel du client, analyse des fichiers de contrôle.

Développeur IA (machine learning) — ENAGEO (groupe Sonatrach), Boumerdès

juil. 2023 – juil. 2024

- CDD à temps partiel en parallèle du M1 SII : reconstruire des mesures de puits (élasticité, densité...) manquantes ou coûteuses à acquérir, chaque série indexée par la profondeur étant traitée comme une série temporelle.
- Imputation dans un même puits par LSTM et RNN (tendance, saisonnalité, cycles) : **MAE 12,7, RMSE 15,2 (LSTM)**.
- Généralisation inter-puits par LSTM : **corrélation portée de 0,52 à 0,82** et **erreurs réduites de 20 à 30 %** par rapport au stage (MAE 21,4 → 15,8, RMSE 27,6 → 20,2).

Stagiaire Machine Learning — ENAGEO (groupe Sonatrach), Boumerdès

févr. – juin 2023

- Prédiction des paramètres géomécaniques de roche réservoir à partir des diagraphies de 3 puits : benchmark régression linéaire / SVM-RBF / perceptron multicouche (Scikit-Learn) évalué en généralisation inter-puits — **MAE ramené de 27,4 à 21,4** par le MLP, corrélation plafonnée à 0,52 et jugée insuffisante pour une mise en production.
- Application livrée aux géophysiciens de l'entreprise : import/export CSV, entraînement des modèles, prédiction des valeurs manquantes et gestion des comptes utilisateurs — Java Swing + Python, MySQL, conception UML.

Projets

- Moteur de recommandation e-commerce temps réel (M2 · 2025)** — architecture de streaming distribuée Kafka → PySpark → MongoDB → Streamlit : 885K événements, catalogue de 24 255 produits, recommandation hybride, scoring en ligne.
- Pipeline de qualité de données (M2 · 2025)** — scoring multicritère (complétude, exactitude, cohérence, unicité) contextualisé par cas d'usage : imputation par régression ($r \approx 0,78$), reconstruction de coordonnées GPS par formule de Haversine, correction d'incohérences temporelles.
- LLM kabyle entraîné from scratch (projet personnel · 2026)** — Transformer decoder-only de 36,3M paramètres en PyTorch (type Llama, 10 couches), tokenizer BPE personnalisé, pré-entraînement sur 107M tokens sur une Tesla T4 puis fine-tuning.
- Benchmark de LLMs open-source (M1 · 2025)** — 3 modèles 7B (LLaMA 2, Mistral, DeepSeek-R1-Distill-Qwen) sur GSM8K, HellaSwag et HumanEval via Ollama, sur 4× NVIDIA L4 : protocole reproductible et analyse du compromis précision/latence.
- Extraction d'expressions temporelles par Transformers (M2 · 2025)** — classification de tokens BERT pour le typage d'entités temporelles (schéma TIMEX3), évaluée sur 3 corpus aux registres contrastés (historique, clinique, tweets) : pipeline automatisé de bout en bout, F1 jusqu'à 95,5 %.
- Imputation de séries temporelles (M1 · 2025)** — 6 stratégies comparées sur 3 127 séries de consommation électrique × 12 864 points (STL GPU, LSTM autoencodeur, U-Net, Transformer) : meilleur MAE 0,262.

Formation

2024–2026 M1 & M2 Données, Connaissances et Intelligence (DCI), Major de promotion — Université Paris Cité

2020–2024 Licence Informatique + M1 SII — USTHB, Alger

2020 Baccalauréat Sciences expérimentales, Mention Bien — Algérie

Langues

Langues : Français (bilingue) · Anglais (bilingue) · Arabe (courant) · Kabyle (langue maternelle)