

Amar Merabti

Ingénieur IA & Data Scientist — Candidat Thèse CIFRE

merabtiamar91@gmail.com · merabtiamar.github.io · Paris, Île-de-France

Profil

M2 IA & Data Science (DCI) à l'Université Paris Cité, major de promotion (16/20). Profil orienté recherche en deep learning et NLP : de l'implémentation d'architectures Transformer from scratch à la conception de protocoles expérimentaux complets (benchmark, ablation, tests appariés). Candidat à une thèse CIFRE pour octobre 2026.

Compétences techniques

Machine Learning : Scikit-Learn, régression linéaire et logistique, Ridge/Lasso, arbres de décision, Random Forest, Gradient Boosting (XGBoost, LightGBM), SVM, k-NN, Naïve Bayes, MLP, K-means, DBSCAN, CAH, ACP, t-SNE, Isolation Forest

Deep Learning : PyTorch, TensorFlow, Keras, multi-GPU, modèles de fondation tabulaires (TabPFN, TabSTAR)

NLP & LLM : Transformers, BERT/DeBERTa, NLI, embeddings BGE-M3, GPT-2, LLaMA, Mistral, DeepSeek, fine-tuning, RAG

Data Engineering : Kafka, Spark, PySpark, MongoDB, SQL/NoSQL, Pandas, NumPy

Data Quality : vérification de fidélité

Séries temporelles : STL, LSTM, Transformers, imputation

Évaluation : ablation, tests appariés, calibration

Langages : Python, Java, C/C++

Web & BI : Power BI, SSIS, HTML/CSS/JS

Expériences professionnelles

Stagiaire Data Scientist — Nricher, Paris

févr. – août 2026

- Chaîne d'enrichissement de catalogues produit en production : algorithmes d'extraction d'attributs par règles et lexiques, normalisation vers le référentiel client, analyse des fichiers de contrôle.
- Mémoire de recherche**, encadré par Pr. Salima Benbernou — vérification des valeurs extraites contre le seul texte source, le catalogue client n'étant pas fiable : verbalisation du couple attribut/valeur en hypothèse, découpage de la description en prémisses et agrégation des scores d'inférence textuelle (mDeBERTa-v3). Benchmark sur 4 catalogues de production : 35 attributs, 30 919 lignes, référence sans annotation manuelle (accord entre sources, injection contrôlée d'erreurs), 5 635 exécutions appariées.
- Comparaison de 3 architectures : règle NLI sans apprentissage (0,808 d'exactitude équilibrée), TabPFN-3 sur scores NLI + embeddings BGE-M3 réduits par ACP (0,925), TabSTAR à lecture native du texte (0,898, coût $\times 28$). Ablation appariée (Wilcoxon) : $-8,9$ points sans les 4 scores d'inférence contre $-1,9$ sans les 50 composantes — c'est l'orientation de la représentation du texte, non sa richesse, qui décide. Décision calibrée : 68 % des valeurs automatisées à 99 % de précision.

Développeur IA (machine learning) — ENAGEO (groupe Sonatrach), Boumerdès

juil. 2023 – juil. 2024

- CDD à temps partiel en parallèle du M1 SII : prédire des mesures de puits (élasticité, densité...) manquantes ou coûteuses à acquérir, chaque série indexée par la profondeur étant traitée comme une série temporelle.
- Imputation dans un même puits par LSTM et RNN (tendance, saisonnalité, cycles) : MAE 12,7, RMSE 15,2 (LSTM).
- Généralisation inter-puits (LSTM), par rapport au stage : corrélation 0,52 $\rightarrow$ 0,82, MAE 21,4 $\rightarrow$ 15,8, RMSE 27,6 $\rightarrow$ 20,2.

Stagiaire Machine Learning — ENAGEO (groupe Sonatrach), Boumerdès

févr. – juin 2023

- Mémoire de licence** (juin 2023) — prédiction des paramètres géomécaniques de roche réservoir à partir des diagraphies de 3 puits, en généralisation inter-puits (test sur un puits jamais vu). Régression linéaire ($r = 0,15$), SVM-RBF (0,29), MLP 100/50 ReLU (0,52, MAE 21,4) : corrélation insuffisante sur des formations hétérogènes. Application Java Swing / Python livrée (MySQL, UML).

Projets de recherche

LLM Kabyle from Scratch

Projet de recherche personnel · 2026

Conception et entraînement from scratch d'un modèle de langue génératif (36,3M paramètres) pour le kabyle, langue peu dotée. Transformer decoder-only type Llama en PyTorch (10 couches, 8 têtes, $d_{model} = 512$, contexte 512, RMSNorm, RoPE, SwiGLU), tokenizer BPE personnalisé. Pré-entraînement sur 107M tokens (1 Tesla T4) puis fine-tuning : $-3,3\%$ de bits par caractère.

Benchmark de LLMs Open-Source

TER (M1) · 2025

Évaluation comparative empirique de 3 LLMs 7B (LLaMA 2, Mistral, DeepSeek-R1-Distill-Qwen) sur GSM8K (8-shot), HellaSwag (0-shot) et HumanEval (0-shot, exécution sandboxée), sur 4 $\times$ NVIDIA L4 via Ollama. Protocole reproductible, analyse des types d'erreurs Python et du compromis précision/latence — DeepSeek 78,0 % sur HumanEval, Mistral 61,2 % sur HellaSwag.

Extraction d'Expressions Temporelles par Transformers

Projet de recherche (M2) · 2025

Évaluation cross-domaine d'un modèle BERT de token classification (Lange et al., 2021) pour le typage TIMEX3, sur 3 corpus aux registres contrastés (historique, clinique, tweets). Pipeline automatisé et alignement au gold standard — F1 jusqu'à 95,5 %.

Imputation de Séries Temporelles

M1, encadré par Pr. Themis Palpanas · 2025

Comparaison de 6 stratégies d'imputation sur 3 127 séries de consommation électrique de 12 864 points, en PyTorch (STL accélérée GPU, LSTM autoencoder, Partial Convolution U-Net, Transformer self-supervisé) — meilleur MAE par la STL-GPU (0,262).

Projets académiques

Data Quality — Détection & Correction d'Incohérences

M2 · 2025

Pipeline multicritère (complétude, exactitude, cohérence, unicité) : imputation par régression ($r \approx 0,78$ entre tarif et distance), reconstruction géométrique de coordonnées GPS (Haversine), correction d'incohérences temporelles.

Moteur de Recommandation E-Commerce Temps Réel

M2 · 2025

Architecture de streaming distribuée (Kafka $\rightarrow$ PySpark $\rightarrow$ MongoDB $\rightarrow$ Streamlit) : catalogue de 24 255 produits issus de 885K événements, recommandation hybride et scoring de pertinence en ligne.

Formation

2024–2026 M1 & M2 Données, Connaissances et Intelligence (DCI), Major de promotion — Université Paris Cité

2020–2024 Licence Informatique + M1 SII — USTHB, Alger

2020 Baccalauréat Sciences expérimentales, Mention Bien — Algérie

Langues & centres d'intérêt

Langues : Français (bilingue) · Anglais (bilingue) · Arabe (courant) · Kabyle (langue maternelle)

Intérêts : IA & Sciences · Langues & Linguistique · Football · Musique · Photographie